

Top1–Top2 Token Olasılık Farkı Cevap Doğruluğu Tahmini: Cosmos-T1 ile Çalışma

Betül Arslan

Hesaplamalı Anlambilim – Proje
betullarslan@gmail.com

Özet—Büyük dil modellerinin (LLM) cevaplarının güvenilirliğini değerlendirmek, özellikle matematik gibi doğrulama gerektiren alanlarda kritik önem taşımaktadır. Bu çalışmada, Cosmos-T1 (ytu-ce-cosmos/Turkish-Gemma-9b-T1) modelinin gsm8k_tr Türkçe matematik veri kümesi üzerindeki üretim sürecinden elde edilen top1–top2 token olasılık fark dizileri analiz edilmiştir. Her cevap için bu diziden 14 istatistiksel özellik çıkarılmış; Logistic Regression, Random Forest ve Gradient Boosting sınıflandırıcıları dengeli bir eğitim kümesi ($n_{\text{train}} = 240$) ve test kümesi ($n_{\text{test}} = 100$) üzerinde karşılaştırılmıştır. Gradient Boosting en yüksek AUC (0.762) ve F1 (0.720) değerlerine ulaşmıştır. Çalışma aynı zamanda token sayısının (n_tokens) chain-of-thought tabanlı modellerde cevap kalitesinin güçlü bir vekil sinyali oluşturduğunu göstermektedir.

Index Terms—büyük dil modelleri, token olasılığı, cevap doğruluğu tahmini, güven kalibrasyonu, Türkçe NLP, Cosmos-T1, chain-of-thought

I. GİRİŞ

Büyük dil modelleri, her üretim adımında kelime dağarcığı (V) üzerinde bir olasılık dağılımı hesaplar ve bu dağılımdan örnekleme yaparak bir sonraki tokeni seçer. Bu süreçte modelin bir adımda ne kadar kararlı olduğu, en yüksek iki token olasılığı arasındaki fark olan *top1–top2 diff* (δ_t) ile ölçülebilir.

Temel soru şudur: Doğru cevap üreten bir model, üretim boyunca sistematik olarak daha yüksek güven sergilemekte midir? Eğer öyleyse, bu güven profilinin istatistiksel özetlerinden cevabın doğru mu yanlış mı olduğu tahmin edilebilir mi?

Bu çalışma söz konusu hipotezi Türkçe matematik soru-cevap bağlamında sınamaktadır. <think> bloğu üzerinden uzun düşünce zinciri oluşturan Cosmos-T1 modeli, gsm8k_tr veri kümesi üzerinde çalıştırılmış; her üretim adımındaki δ_t değerleri LogitsProcessor aracılığıyla toplanmıştır.

t adımıdaki top1–top2 farkı şöyle tanımlanır:

$$\delta_t = P(\hat{y}_t^{(1)} \mid x, y_{<t}) - P(\hat{y}_t^{(2)} \mid x, y_{<t}), \quad t = 1, \dots, T \quad (1)$$

burada $\hat{y}_t^{(1)}$ ve $\hat{y}_t^{(2)}$ sırasıyla t . adımda en yüksek ve ikinci en yüksek olasılıklı tokenları, x giriş sorusunu ve T üretilen toplam token sayısını göstermektedir. $\delta_t \in [0, 1]$ aralığındadır; yüksek değerler kararlı kararı, düşük değerler belirsizliği temsil eder.

Çalışmanın temel katkıları şunlardır:

- output_scores=True yerine LogitsProcessor tabanlı bellek-verimli sinyal toplama yöntemi.
- gsm8k_tr veri kümesine özgü Türkçe altın cevap çıkarma sürecinin tasarımı.
- Top1–top2 fark dizisinden çıkarılan 14 özelliğin sınıflandırma katkısının analizi ve n_tokens'ın vekil sinyal karakterinin ortaya konması.

II. İLGİLİ ÇALIŞMALAR

Token düzeyindeki olasılık bilgisini LLM güvenilirliği için kullanan yaklaşımlar son iki yılda hız kazanmıştır.

HALT [4], hallüsinasyon tespitini gerçek zamanlı olarak gerçekleştirmek amacıyla üretim adımlarındaki entropi değişimini izlemektedir. Belirsizlik eşiği aşıldığında sistem uyarı vermekte; bu yapı, token olasılık dağılımının hatayı ne ölçüde önceden işaret ettiğini ortaya koymaktadır.

Entropy Sentinel [5], Shannon entropisini anlık güven ölçütü olarak benimser. Yüksek entropi anlamsal belirsizliğe, düşük entropi ise kararlılığa karşılık geldiğini deneysel olarak doğrulamaktadır. Çalışmamızdaki düşük güven oranı özellikleri (prop_low_01, prop_low_02) bu yaklaşımdan ilham almaktadır.

ToKUR [6], top- k olasılık farklarını bir güven çerçevesi içinde kullanıcıya raporlayan yapısal bir sistem sunmaktadır. Çalışmamızda kullandığımız top1–top2 farkının anlamlı bir belirsizlik ölçütü olduğunu desteklemektedir.

LogitScope [7], logit dağılımını bir zaman serisi olarak ele alıp eğilim ve varyans tabanlı özellikler çıkarmaktadır. Bizim özellik mühendisliği tasarımı, özellikle trend ve konumsal özellikler bakımından bu yaklaşımdan doğrudan faydalanmıştır.

Mevcut çalışma bu literatürden iki açıdan ayrılmaktadır: (1) Türkçe matematik muhakemesi yapan, chain-of-thought tabanlı bir model incelenmiştir; (2) token düzeyinde anlık karar yerine cevap düzeyinde sınıflandırma yapılmıştır. Öte yandan model kartında önerilen token limiti 4096 iken çalışmamızda zaman kısıtı nedeniyle 1024 kullanılmıştır; bu sınırlamanın olası etkileri Bölüm VI'da ele alınmaktadır.

III. MODEL VE VERİ KÜMESİ

A. Cosmos-T1

ytu-ce-cosmos/Turkish-Gemma-9b-T1 (Cosmos-T1), Gemma-2 9B mimarisi üzerine Türkçe matematik prob-

lemlerini çözmek için ince ayar yapılmış bir modeldir [1]. Model, cevap üretmeden önce <think> bloğu içinde adım adım akıl yürütme (chain-of-thought, CoT) gerçekleştirir; bu yapı üretilen token sayısını önemli ölçüde artırmaktadır.

Model kartında belirtilen parametreler bu çalışmada eksiksiz uygulanmıştır: `do_sample=True`, `temperature=0.6`, `top_p=0.95`, `top_k=20`. Greedy decoding (açgözlü çözüme) kullanılmamıştır; zira model kartı bu yöntemi açıkça dışlamaktadır.

B. gsm8k_tr Veri Kümesi

`ytu-ce-cosmos/gsm8k_tr` [2], GSM8K [3] İngilizce matematik sorularının Türkçeye çevrilmiş halidir ve 8792 eğitim örneği içerir. İngilizce orijinalinin aksine cevaplar ##### <sayı> biçiminde değil, düz Türkçe metin olarak verilmektedir; bu durum altın cevap çıkarmayı güçleştirmektedir.

Veri temizleme: Türkçede saat formatı (SS:DD) ile ifade edilen cevaplar (ör. “8:30”) son rakam çıkarmada sistematik hataya yol açmaktadır. Bu tür 34 örnek filtrelenmiş, geriye **8734 temiz örnek** kalmıştır. Türkçede ondalık ve binler ayraçlarının birbirinin yerine kullanılabilmesi nedeniyle tüm sayısal değerler `sayi_temizle()` işleviyle standartlaştırılmıştır.

IV. YÖNTEM

A. Top1–Top2 Fark Dizisinin Toplanması

Standart `output_scores=True` yaklaşımı tüm adım logitlerini bellekte tuttuğundan yüksek VRAM tüketimine neden olmaktadır. Bu çalışmada `LogitsProcessor` tabanlı bellek-verimli bir yöntem benimsenmiştir:

```
class Top1Top2Kaydedici(LogitsProcessor):
    def __init__(self):
        self.farklar = []

    def __call__(self, input_ids, scores):
        probs = torch.softmax(
            scores.float(), dim=-1)
        top2 = torch.topk(probs, k=2,
                          dim=-1).values
        fark = (top2[:, 0] - top2[:, 1])
                .detach().cpu().tolist()
        self.farklar.append(fark)
        return scores
```

Her adımda yalnızca tek bir skalar (δ_t) saklanmakta; logit vektörünün tamamı bellekte tutulmamaktadır. Böylece $T = 1024$ tokenlık uzun üretimlerde bile bellek kullanımı sabit kalmaktadır.

B. Üretim Yapılandırması

Tablo 1
ÜRETİM PARAMETRELERİ

Parametre	Değer
Model	Turkish-Gemma-9b-T1
<code>max_new_tokens</code>	1024
<code>temperature</code>	0.6
<code>top_p</code>	0.95
<code>top_k</code>	20
<code>do_sample</code>	True
Donanım	A100 40 GB, bfloat16
Toplam üretim	357 soru / $\approx$ 431 dk

`max_new_tokens=1024` değeri, modelin CoT bloğunu tamamlayıp nihai cevaba ulaşabilmesi için zorunludur. Daha düşük değerlerde (ör. 128 veya 512) model düşünce bloğunu tamamlayamadan kesilmekte ve sayısal bir cevap üretememektedir.

C. Özellik Mühendisliği

Her cevaba ait $\delta = [\delta_1, \delta_2, \dots, \delta_T]$ dizisinden 14 istatistiksel özellik çıkarılmaktadır. Bu özellikler, dizi uzunluğundan bağımsız olarak her cevabı sabit boyutlu ($\mathbb{R}^{14}$) bir vektörle temsil eder ve makine öğrenmesi modelinin girişini oluşturur. Özellikler üç temel gerekçeyle seçilmiştir: (1) dizi uzunluğundan bağımsız sabit boyutlu temsil sağlamaları, (2) dağılımın farklı istatistiksel yönlerini (merkez, yayılım, kuyruk, zamansal konum ve eğilim) birbirini tamamlayacak biçimde örtmeleri, (3) hesaplama maliyetlerinin düşük ve yorumlanabilirliklerinin yüksek olması.

1) Ortalama (*mean*):

$$\mu = \frac{1}{T} \sum_{t=1}^T \delta_t \quad (2)$$

Tüm üretim boyunca ortalama güveni ölçer. Yüksek μ modelin genel olarak kararlı kararlar verdiğini, düşük μ ise sık belirsiz adımlar içerdiğini gösterir.

2) Medyan (*median*):

$$\tilde{\delta} = F^{-1}(0.50) \quad (3)$$

Uç değerlere duyarsız merkezi eğilim ölçütüdür. Tek bir çok düşük δ_t değeri medyana çarpmaz; bu nedenle ortalamaya tamamlayıcı bir perspektif sunar.

3) Standart Sapma (*std*):

$$\sigma = \sqrt{\frac{1}{T} \sum_{t=1}^T (\delta_t - \mu)^2} \quad (4)$$

Güvenin üretim boyunca ne kadar dalgalandığını ölçer. Yüksek σ bazı adımlarda çok emin bazılarında ise çok belirsiz olduğunu; düşük σ ise tutarlı bir güven profilini yansıtır.

4) Minimum ve Maksimum (*min*, *max*):

$$\delta_{\min} = \min_t \delta_t, \quad \delta_{\max} = \max_t \delta_t \quad (5)$$

$\delta_{\min}$ üretimdeki en kritik belirsizlik anını, $\delta_{\max}$ ise en kararlı adımı temsil eder. Tek başına bilgi taşıma kapasiteleri sınırlıdır; diğer özelliklerle birlikte dağılım şeklini tamamlamak amacıyla dahil edilmişlerdir.

5) Çeyrekler ve Çeyrekler Arası Aralık (*q25*, *q75*, *iqr*):

$$Q_{25} = F^{-1}(0.25), \quad Q_{75} = F^{-1}(0.75), \quad IQR = Q_{75} - Q_{25} \quad (6)$$

burada F^{-1} ampirik dağılım fonksiyonunun tersidir. Ortalama ve standart sapmanın uç değerlere duyarlılığını gidermek amacıyla eklenmiştir. IQR, güven profilinin heterojenliğini uç değerlerden bağımsız biçimde ölçer.

6) İlk ve Son 10 Token Ortalaması ($mean_first10$, $mean_last10$):

$$\mu_{first10} = \frac{1}{\min(10, T)} \sum_{t=1}^{\min(10, T)} \delta_t \quad (7)$$

$$\mu_{last10} = \frac{1}{\min(10, T)} \sum_{t=\max(1, T-9)}^T \delta_t \quad (8)$$

Global istatistiklerin yakalayamadığı zamansal konuma duyarlı bilgiyi sağlar. $\mu_{first10}$ çözüm yolunun doğru kurulup kurulmadığını erken dönemde işaret ederken; μ_{last10} modelin cevaba yaklaşırken güvenini yitirip yitirmediğini ölçer. LogitScope [7] bu tür konumsal özelliklerin sınıflandırma katkısını deneysel olarak göstermiştir.

7) Düşük Güven Oranları ($prop_low_01$, $prop_low_02$):

$$p_{<0.10} = \frac{1}{T} \sum_{t=1}^T \mathbf{1}[\delta_t < 0.10] \quad (9)$$

$$p_{<0.20} = \frac{1}{T} \sum_{t=1}^T \mathbf{1}[\delta_t < 0.20] \quad (10)$$

burada $\mathbf{1}[\cdot]$ gösterge fonksiyonudur. Entropy Sentinel [5] çalışmasından ilham alınarak tasarlanmıştır. İki farklı eşik ($\theta = 0.10$ ve $\theta = 0.20$) kullanılması, hem şiddetli belirsizlik anlarını hem de orta düzey dalgalanmaları ayrı ayrı temsil etmek içindir.

8) Doğrusal Eğilim ($trend$):

$$\hat{\delta}_t = \alpha \cdot t + \beta, \quad trend = \hat{\alpha} = \frac{\sum_{t=1}^T (t - \bar{t})(\delta_t - \mu)}{\sum_{t=1}^T (t - \bar{t})^2} \quad (11)$$

En küçük kareler yöntemiyle diziye uydurulmuş birinci dereceden polinomun eğim katsayısıdır. Global istatistikler güven profilinin düzeyini özetlerken, trend zamansal değişim yönünü yakalar. Negatif $\hat{\alpha}$, üretim ilerledikçe güvenin azaldığını gösterir; bu durum modelin çözüm yolunu sürdürmeyi belirsizliğe düştüğünün sinyalidir.

9) Token Sayısı (n_tokens):

$$n_{tokens} = T \quad (12)$$

Üretilen toplam token sayısıdır. Doğrudan bir güven ölçütü olmamakla birlikte, CoT tabanlı bu modelde yanlış cevap üretilirken çözüm bloğunun tamamlanamaması ve max_new_tokens sınırına çarpılması nedeniyle cevap kalitesinin bir vekil sinyali (proxy) olarak işlev görmektedir.

Tüm 14 özellik Tablo II'de özetlenmektedir.

Tablo II
ÇIKARILAN 14 ÖZELLİK

Özellik	Formül	Yorumu
n_tokens	Denklem 12	Üretilen token sayısı
mean	Denklem 2	Genel güven ortalaması
std	Denklem 4	Güven dalgalanması
min	Denklem 5	En belirsiz adım
max	Denklem 5	En kararlı adım
median	Denklem 3	Merkezi eğilim
q25	Denklem 6	Alt çeyrek
q75	Denklem 6	Üst çeyrek
iqr	Denklem 6	Güven yayılımı
mean_first10	Denklem 7	Başlangıç güveni
mean_last10	Denklem 8	Bitiş güveni
prop_low_01	Denklem 9	Yüksek belirsizlik oranı
prop_low_02	Denklem 10	Orta belirsizlik oranı
trend	Denklem 11	Güven değişim eğilimi

D. Sınıflandırma Modelleri ve Veri Bölümleme

Toplam 357 soru üretilmiş; 187 doğru ve 170 yanlış cevap elde edilmiştir. Sınıf dengesini sağlamak için her sınıftan 170 örnek seçilmiş, bunlar çakışmayacak biçimde eğitim ve test kümelerine ayrılmıştır (Tablo III).

Tablo III
DENGELİ VERİ KÜMESİ BÖLÜMLEME

Küme	Doğru	Yanlış	Toplam
Eğitim	120	120	240
Test	50	50	100
Top.	170	170	340

Üç sınıflandırıcı değerlendirilmiştir:

- **Logistic Regression (LR):** Doğrusal taban çizgisi. StandardScaler normalleştirilmesi ile $max_iter=1000$.
- **Random Forest (RF):** 300 karar ağacından oluşan topluluk modeli. Doğrusal olmayan özellik etkileşimlerini yakalayabilir.
- **Gradient Boosting (GB):** Artımlı öğrenme ile zayıf öğrenicileri birleştiren topluluk yöntemi. Sklearn varsayılan hiperparametreleri.


V. SONUÇLAR

A. Model Performansı

Tablo IV
ML MODEL KARŞILAŞTIRMASI ($n_{TRAIN} = 240$, $n_{TEST} = 100$)


Model	Acc	Prec	Rec	F1	AUC
LR	0.720	0.844	0.540	0.659	0.738
RF	0.700	0.727	0.640	0.681	0.747
GB	0.720	0.720	0.720	0.720	0.762

B. Token Bazlı Fark Dizisi




Şekil 1. Doğru ve yanlış cevap örneklerinde token bazlı δ_t dizisi. Her iki örnek de yüksek frekanslı dalgalanma sergilemektedir; ancak doğru cevap (yeşil) orta bölgede görece daha kararlı bir profil sürdürmektedir.

C. Ortalama Top1-Top2 Fark Dağılımı




Şekil 2. Doğru ve yanlış cevaplarda ortalama δ_t farkının dağılımı. İki dağılım büyük ölçüde örtüşmektedir; bu durum tek bir eşikle mükemmel ayırım yapılamayacağını, ancak birleşik özelliklerin anlamlı tahmin sağladığını göstermektedir.

D. Confusion Matrix




Şekil 3. Üç modele ait confusion matrix'ler (100 test örneği, 50 doğru + 50 yanlış). LR: TN=45, FP=5, FN=23, TP=27. RF: TN=38, FP=12, FN=18, TP=32. GB: TN=36, FP=14, FN=14, TP=36.

E. ROC Eğrisi



Şekil 4. Üç modelin ROC eğrileri. Kesikli diyagonal şans düzeyini temsil etmektedir. GB (AUC=0.762), RF (AUC=0.747) ve LR (AUC=0.738) sıralamasıyla tüm modeller rastgele tahminin belirgin biçimde üzerindedir.

F. Özellik Önemi



Şekil 5. Random Forest (yeşil) ve Gradient Boosting (turuncu) modellerine ait özellik önem sıralaması. Her iki modelde de `n_tokens` açık ara birinci konumdadır.

VI. TARTIŞMA

A. Özellik Önemi Analizi

Şekil 5, her iki modelde de `n_tokens`'ın açık ara en önemli özellik olduğunu ortaya koymaktadır. Bu bulgu CoT tabanlı modelin davranışıyla tutarlıdır: yanlış cevap üretirken model düşünce bloğunu tamamlayamamakta ve `max_new_tokens=1024` sınırına çarpmaktadır. Doğru cevaplarda ise model genellikle bu sınıra ulaşmadan sona ermektedir. Dolayısıyla `n_tokens`, cevap kalitesinin bir *vekil sinyali* (proxy) işlevi görmektedir.

Random Forest'ta `q75` ve `mean_last10` öne çıkarken Gradient Boosting'de `mean_first10` ve `prop_low_01` ikinci ve üçüncü konumdadır. Bu iki özellik seti birbirini tamamlamaktadır: RF üretimin sonundaki güveni (`mean_last10`) ve dağılımın üst çeyreğini (`q75`) önemserken, GB üretimin başındaki güveni (`mean_first10`) ve yüksek belirsizlik oranını (`prop_low_01`) öne çıkarmaktadır.

min ve max özellikleri her iki modelde de sıfıra yakın önem aldığından tek başına bilgi taşımadıkları görülmektedir. Uç değerler yerine dağılımın orta kesimini (IQR, çeyrekler) özetleyen özellikler daha istikrarlı sinyal sağlamaktadır.

B. Algoritmalar Arası Önem Farklılığı

Her iki modelde de `n_tokens` birinci sırada yer alması sinyalin algoritma seçiminden bağımsız olarak güçlü ve tutarlı olduğunu göstermektedir. Buna karşın diğer özelliklerin sıralaması modelden modele farklılık göstermektedir; bunun nedeni her algoritmanın önem kavramını farklı biçimde ölçmesidir.

Random Forest'ta özellik önemi, bir özelliğin kullanıldığı tüm düğümlerde sağladığı ortalama Gini safsızlığı azalmasıdır. Her ağaçta rastgele özellik alt kümeleri seçildiğinden sonuç istatistiksel bir ortalamadır; özellikler arasındaki doğrusal olmayan etkileşimler yakalanabilir.

Gradient Boosting'de önem, her adımda artık hatayı en çok azaltan özelliğe göre belirlenir. Öğrenme süreci iteratif olduğundan bazı özellikler erken adımlarda baskın çıkarken bazıları yalnızca belirli hata bölgelerinde devreye girer. Örneğin `trend` GB'de dördüncü sıradayken RF'de beşinci konumdadır; GB hata üzerine hata öğrenirken güven eğilimi sinyalini erken adımda fark etmektedir.

Logistic Regression ise her özelliği doğrudan bir katsayıyla ağırlandırdığından yalnızca etiketle doğrusal ilişki kuran özellikler öne çıkar. Bu, LR'nin diğer iki modele kıyasla daha düşük F1 (0.659) sergilemesinin temel nedenidir.

C. Model Karşılaştırması

Tablo IV incelendiğinde LR'nin yüksek Precision (0.844) ancak düşük Recall (0.540) sergilediği görülmektedir; model doğru tahmin ettiğinde güvenilirdir ancak 50 doğru cevabın 23'ünü kaçırmaktadır. Bu asimetri, LR'nin doğrusal karar sınırının özellik uzayını yeterince bölememesinden kaynaklanmaktadır.

GB ise Accuracy, Recall, F1 ve AUC metriklerinde dengeli ve lider bir profil sergilemektedir. Confusion matrix'te (Şekil 3) GB'nin TN=36, FP=14, FN=14, TP=36 değerleriyle simetrik bir hata dağılımı gösterdiği dikkat çekmektedir; bu, sınıflar arası karar eşliğinin dengeli konumlandığına işaret etmektedir.

D. Sınırlılıklar

- 1) **Token limiti ve vekil sinyal:** `n_tokens`'ın baskın özellik olması, sınıflandırıcının kısmen "model çözümü tamamladı mı?" sorusunu yanıtladığına işaret etmektedir. Token limiti 4096'ya yükseltildiğinde bu vekil etkinin zayıflayacağı ve gerçek güven sinyalinin katkısının daha net görüleceği beklenmektedir.
- 2) **Altın cevap gürültüsü:** `gsm8k_tr`'deki düz metin formatı nedeniyle bazı örneklerde altın cevap yanlış çıkarılmış olabilir; bu durum etiket gürültüsüne yol açarak gerçek başarıyı olduğundan düşük gösterebilir.
- 3) **Veri kümesi büyüklüğü:** 240 eğitim örneği topluluk yöntemleri için sınırlıdır. Daha büyük veri kümeleriyle başarımın artması beklenmektedir.

VII. SONUÇ

Bu çalışma, Cosmos-T1 modelinin üretim sürecinde token adımı başına hesaplanan `top1-top2` olasılık farklarından çıkarılan 14 istatistiksel özelliğin, cevap doğruluğunu otomatik olarak tahmin etmeye yettiğini göstermiştir. Gradient Boosting AUC=0.762 ve F1=0.720 ile en dengeli performansı sergilemiştir; tüm modeller AUC > 0.73 elde etmiş ve sinyalin rastgele tahminden anlamlı biçimde üstün olduğu kanıtlanmıştır.

En belirleyici sinyalin `n_tokens` olması, chain-of-thought tabanlı modellerde cevap kalitesiyle üretim uzunluğu arasındaki ilişkiye dair yorumlanabilir bir içgörü sunmaktadır. Token limitini aşan model büyük olasılıkla çözümü tamamlayamamış ve yanlış cevap vermiştir. Bunu izleyen `q75`, `mean_first10`, `mean_last10` ve `trend` özellikleri üretim boyunca güven profilinin nasıl şekillendiğini yansıtmaktadır.

Sonuç olarak, herhangi bir dış doğrulama kaynağı gerektirmeyen bu iç sinyal tabanlı yaklaşım, Türkçe matematik muhakemesi bağlamında LLM güvenilirlik tespiti için umut verici bir temel oluşturmaktadır.

KAYNAKLAR

- [1] YTU CE Cosmos, "Turkish-Gemma-9b-T1," Hugging Face, 2024. [Online]. <https://huggingface.co/ytu-ce-cosmos/Turkish-Gemma-9b-T1>
- [2] YTU CE Cosmos, "gsm8k_tr," Hugging Face, 2024. [Online]. https://huggingface.co/datasets/ytu-ce-cosmos/gsm8k_tr
- [3] K. Cobbe et al., "Training Verifiers to Solve Math Word Problems," *arXiv:2110.14168*, 2021.
- [4] P. Varshney et al., "HALT: Hallucination Detection via Token-Level Uncertainty in Large Language Models," *arXiv:2602.02888*, 2025.
- [5] R. Chen et al., "Entropy Sentinel: Real-Time Hallucination Detection Through Token-Level Entropy Monitoring," *arXiv:2601.09001*, 2025.
- [6] M. Kim et al., "ToKUR: Token-Level Uncertainty Reporting for Trustworthy LLM Outputs," *arXiv:2505.11737*, 2025.
- [7] H. Liu et al., "LogitScope: Analyzing Logit Distributions for LLM Confidence Estimation," *arXiv:2603.24929*, 2025.
- [8] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.